

ANALISIS SEGMENTASI PELANGGAN MENGGUNAKAN ALGORITMA K-MEANS PADA DATA TRANSAKSI PENJUALAN

(Customer Segmentation Analysis Using the K-Means Algorithm on Sales Transaction Data)

Muhammad Rifqy Habibi¹⁾, Ade Ratu Safitri²⁾, Sri Zul'aini Ulya³⁾, Muhammad Asrofi Sazani⁴⁾

Program Studi Teknik Informatika Universitas Mataram

rifqyh144@gmail.com, aderatusafitr@gmail.com, srizulainiulya@gmail.com, asrofisazani@gmail.com

Abstrak

Pertumbuhan volume data transaksi penjualan yang semakin pesat menuntut kemampuan analitik yang efisien guna menghasilkan wawasan bisnis yang bermakna. Segmentasi pelanggan merupakan salah satu pendekatan strategis dalam memahami pola perilaku konsumen, sehingga perusahaan dapat merancang strategi pemasaran yang lebih tepat sasaran. Algoritma K-Means dikenal sebagai metode clustering yang efektif untuk mengelompokkan pelanggan berdasarkan kesamaan karakteristik transaksi. Namun, ketika diterapkan pada dataset berskala besar, algoritma ini menghadapi tantangan komputasi yang signifikan berupa waktu pemrosesan yang panjang dan konsumsi sumber daya yang tinggi. Pemrosesan sekuensial konvensional tidak lagi memadai untuk menangani beban kerja tersebut secara efisien. Penelitian ini mengusulkan solusi berupa implementasi algoritma K-Means secara paralel menggunakan Message Passing Interface (MPI), yang memungkinkan distribusi beban komputasi ke beberapa prosesor secara bersamaan. Setiap prosesor memproses subset data secara independen, dan hasil pengelompokan kemudian dikombinasikan melalui mekanisme komunikasi antar proses yang disediakan oleh MPI. Eksperimen dilakukan pada data transaksi penjualan nyata dengan variasi jumlah prosesor untuk mengukur peningkatan performa. Hasil pengujian menunjukkan bahwa pendekatan paralel berbasis MPI mampu mereduksi waktu komputasi secara signifikan dibandingkan pendekatan sekuensial, dengan tetap mempertahankan akurasi segmentasi yang setara. Penelitian ini memberikan kontribusi pada pengembangan metode analisis data berskala besar yang efisien, serta membuka peluang penerapan komputasi paralel pada domain kecerdasan bisnis lainnya.

Kata kunci: Segmentasi pelanggan, algoritma K-Means, komputasi paralel, Message Passing Interface (MPI), data transaksi penjualan, clustering, kecerdasan bisnis

Abstract

The rapid growth of sales transaction data demands efficient analytical capabilities to generate meaningful business insights. Customer segmentation is a key strategic approach for understanding consumer behavioral patterns, enabling companies to design more targeted marketing strategies. The K-Means algorithm is widely recognized as an effective clustering method for grouping customers based on shared transactional characteristics. However, when applied to large-scale datasets, the algorithm faces significant computational challenges, including prolonged processing times and high resource consumption. Conventional sequential processing is no longer sufficient to handle such workloads efficiently. This study proposes the implementation of a parallelized K-Means algorithm using Message Passing Interface (MPI), which enables the distribution of computational workloads across multiple processors simultaneously. Each processor independently handles a subset of the data, and the clustering results are subsequently consolidated through MPI's inter-process communication mechanisms. Experiments were conducted on real-world sales transaction data with varying numbers of processors to measure performance improvements. The results demonstrate that the MPI-based parallel approach significantly reduces computation time compared to the sequential method, while maintaining equivalent segmentation accuracy. This research contributes to the development of efficient large-scale data analysis methods and opens opportunities for the broader application of parallel computing in other business intelligence domains.

Keyword: Customer segmentation, K-Means algorithm, parallel computing, Message Passing Interface (MPI), sales transaction data, clustering, business intelligence

I. PENDAHULUAN

Perkembangan teknologi informasi yang pesat telah mendorong meningkatnya jumlah data yang dihasilkan, khususnya dalam bidang bisnis dan e-commerce. Data transaksi penjualan menjadi salah satu sumber informasi penting karena mencerminkan perilaku pelanggan, pola pembelian, serta preferensi terhadap produk tertentu. Pemanfaatan data tersebut secara optimal dapat membantu perusahaan dalam menyusun strategi bisnis yang lebih efektif dan berbasis data (data-driven decision making) [1].

Namun, pada kenyataannya masih banyak pelaku usaha yang belum memanfaatkan data transaksi secara maksimal. Pengolahan data yang masih dilakukan secara manual atau belum terstruktur menyebabkan informasi yang dihasilkan kurang akurat dan tidak mampu memberikan gambaran yang jelas mengenai segmentasi pelanggan. Hal ini berdampak pada kurang optimalnya strategi pemasaran, pengelolaan stok, serta pengambilan keputusan bisnis [2].

Untuk mengatasi permasalahan tersebut, diperlukan pendekatan analisis data yang mampu mengolah data dalam jumlah besar secara efisien, yaitu data mining dengan metode clustering. Clustering merupakan teknik pengelompokan data berdasarkan kemiripan karakteristik tanpa label sebelumnya. Salah satu algoritma yang banyak digunakan adalah K-Means karena sederhana, mudah diimplementasikan, dan mampu memproses data dengan cepat [3].

Penelitian ini menggunakan pendekatan kuantitatif dengan algoritma K-Means untuk melakukan segmentasi pelanggan berdasarkan data transaksi penjualan. Dataset yang digunakan berupa data transaksi e-commerce sekitar 4000 pelanggan selama satu tahun, dari 1 Desember 2010 hingga 9 Desember 2011, yang digunakan untuk menganalisis pola perilaku pelanggan dan mendukung prediksi pembelian di masa mendatang.

Penelitian ini juga mengembangkan sistem yang mampu mengotomatisasi segmentasi pelanggan melalui penerapan algoritma K-Means. Sistem dirancang untuk pemrosesan data secara terstruktur, mulai dari tahap input data, pra-pemrosesan, hingga proses clustering. Untuk meningkatkan efisiensi pengolahan data, penelitian ini mempertimbangkan penerapan komputasi paralel sehingga dapat mempercepat waktu eksekusi.

Dengan demikian, penelitian ini bertujuan untuk menghasilkan segmentasi pelanggan yang

lebih akurat serta meningkatkan efisiensi pengolahan data transaksi. Hasil penelitian ini diharapkan dapat memberikan insight yang berguna dalam memahami karakteristik pelanggan, mendukung pengambilan keputusan bisnis, serta meningkatkan efektivitas strategi pemasaran.

II. TINJAUAN PUSTAKA

Penelitian mengenai segmentasi pelanggan menggunakan algoritma K-Means telah banyak dilakukan karena metode ini dinilai efektif dalam mengelompokkan data berdasarkan kemiripan karakteristik pelanggan. Penelitian oleh Hidayat dkk. menerapkan data mining menggunakan algoritma K-Means untuk melakukan segmentasi pelanggan berdasarkan data transaksi penjualan. Hasil penelitian menunjukkan bahwa metode K-Means mampu membantu perusahaan dalam memahami pola perilaku pelanggan sehingga strategi pemasaran dapat dilakukan secara lebih terarah [4].

Penelitian lain dilakukan oleh Prasetyo dan Wibowo yang menerapkan metode K-Means pada data pelanggan untuk menghasilkan kelompok pelanggan berdasarkan tingkat aktivitas transaksi. Penelitian tersebut menunjukkan bahwa proses clustering dapat membantu perusahaan dalam menentukan prioritas layanan dan strategi promosi. Namun, penelitian tersebut masih menggunakan pendekatan pemrosesan sekuensial sehingga waktu eksekusi meningkat seiring bertambahnya jumlah data [5].

Selanjutnya, penelitian oleh Sari dkk. mengimplementasikan algoritma K-Means untuk segmentasi pelanggan pada data penjualan dengan tujuan meningkatkan efektivitas pemasaran. Penelitian tersebut menggunakan atribut transaksi pelanggan sebagai dasar pengelompokan data dan menghasilkan beberapa cluster pelanggan dengan karakteristik berbeda. Penelitian ini menunjukkan bahwa algoritma K-Means cukup efektif dan mudah diterapkan dalam analisis data penjualan [6].

Selain itu, Syari dkk. menerapkan algoritma K-Means pada pengelompokan menu favorit menggunakan pendekatan data mining. Penelitian tersebut menegaskan bahwa K-Means memiliki keunggulan dalam pengolahan data berukuran besar karena proses iterasinya sederhana dan cepat. Akan tetapi, sistem yang digunakan masih berjalan secara serial sehingga performa komputasi masih terbatas pada kemampuan satu prosesor [7].

Di sisi lain, penelitian mengenai

komputasi paralel menggunakan Message Passing Interface (MPI) dilakukan oleh Lumenta dkk. Penelitian tersebut membahas performa PC cluster menggunakan MPI untuk meningkatkan efisiensi pemrosesan data pada sistem distributed memory. Hasil penelitian menunjukkan bahwa MPI mampu mempercepat proses komputasi melalui pembagian tugas ke beberapa proses secara paralel. Namun, penelitian tersebut tidak diterapkan secara khusus pada segmentasi pelanggan maupun algoritma K-Means [8].

Penelitian terbaru oleh Yahya dan Kurniawan mengimplementasikan algoritma K-Means untuk pengelompokan data penjualan berdasarkan pola transaksi. Penelitian ini membuktikan bahwa K-Means efektif digunakan untuk mengidentifikasi pola penjualan dan perilaku pelanggan berdasarkan karakteristik transaksi. Akan tetapi, penelitian tersebut masih menggunakan pendekatan clustering konvensional tanpa penerapan paralelisasi sehingga waktu pemrosesan meningkat ketika jumlah data semakin besar [9].

Berdasarkan beberapa penelitian sebelumnya, dapat diketahui bahwa sebagian besar penelitian hanya berfokus pada penerapan algoritma K-Means untuk segmentasi pelanggan tanpa memperhatikan efisiensi komputasi. Sementara itu, penelitian mengenai MPI umumnya hanya membahas percepatan komputasi tanpa dikombinasikan dengan analisis segmentasi pelanggan. Oleh karena itu, penelitian ini mengembangkan pendekatan yang menggabungkan algoritma K-Means dan komputasi paralel menggunakan MPI dalam proses segmentasi pelanggan berdasarkan data transaksi penjualan. Perbedaan utama penelitian ini dibandingkan penelitian sebelumnya terletak pada penerapan paralelisasi pada proses clustering sehingga sistem tidak hanya mampu menghasilkan segmentasi pelanggan secara otomatis dan akurat, tetapi juga meningkatkan efisiensi waktu komputasi. Hasil penelitian menunjukkan bahwa penerapan MPI mampu menurunkan waktu komputasi secara signifikan pada data berukuran besar dibandingkan metode serial yang digunakan pada penelitian sebelumnya. Dengan demikian, penelitian ini memberikan kemajuan berupa integrasi analisis clustering dan optimasi performa komputasi dalam pengolahan data transaksi berskala besar.

III. METODOLOGI PENELITIAN

Penelitian ini menggunakan pendekatan kuantitatif dengan menerapkan algoritma *clustering*, yaitu *K-Means*, untuk melakukan segmentasi pelanggan berdasarkan data transaksi penjualan. Dataset yang digunakan merupakan data transaksi *e-commerce* yang mencatat aktivitas pembelian sekitar 4000 pelanggan dalam kurun waktu satu tahun, yaitu dari 1 Desember 2010 hingga 9 Desember 2011. Data ini mencakup informasi transaksi yang dapat digunakan untuk menganalisis pola perilaku pelanggan serta mendukung prediksi pembelian di masa mendatang.

A. Perencanaan Penelitian

Perancangan penelitian ini dilakukan sebagai upaya untuk mengembangkan sistem yang mampu mengotomatisasi proses segmentasi pelanggan serta meningkatkan efisiensi pengolahan data melalui penerapan komputasi paralel. Sistem yang dirancang memanfaatkan algoritma *K-Means* sebagai metode utama dalam proses pengelompokan data transaksi pelanggan.

B. Perancangan Sistem

Perancangan sistem dalam penelitian ini bertujuan untuk membangun alur pemrosesan data transaksi pelanggan secara terstruktur dan otomatis menggunakan algoritma *K-Means*. Sistem dirancang dimulai dari proses input dataset, dilanjutkan dengan tahap pra-pemrosesan data untuk memastikan kualitas data yang digunakan, kemudian dilakukan proses *clustering* dengan membagi data ke dalam tiga kelompok berdasarkan kemiripan karakteristik. Hasil dari proses tersebut berupa segmentasi pelanggan serta informasi waktu eksekusi yang digunakan sebagai dasar analisis percepatan (*speedup*), sehingga sistem tidak hanya menghasilkan pengelompokan data, tetapi juga evaluasi efisiensi komputasi.

C. Metode Pengembangan Sistem

Metode pengembangan sistem yang digunakan dalam penelitian ini adalah model waterfall, yaitu pendekatan pengembangan perangkat lunak yang dilakukan secara bertahap dan sistematis.

Tahapan dalam metode waterfall yang diterapkan pada penelitian ini meliputi:



Gambar 1. Tahap Penelitian

1. Analisis Kebutuhan

Pada tahap ini dilakukan identifikasi kebutuhan sistem berdasarkan permasalahan yang ada, yaitu proses pengolahan data transaksi yang masih manual dan belum mampu menghasilkan analisis segmentasi pelanggan secara efektif.

2. Perancangan Sistem

Tahap ini mencakup perancangan alur sistem, struktur proses, serta desain input dan output. Selain itu, pada tahap ini juga dirancang mekanisme penerapan algoritma *K-Means* serta skenario eksekusi paralel.

3. Implementasi

Pada tahap ini dilakukan proses pengkodean sistem menggunakan bahasa pemrograman yang mendukung komputasi paralel. Implementasi mencakup proses pra-pemrosesan data, perhitungan *clustering*, serta pembagian proses ke dalam beberapa pekerja (thread).

4. Simulasi Pengujian

Sistem yang telah dibangun kemudian diuji untuk memastikan fungsionalitas berjalan dengan baik. Pengujian juga dilakukan untuk membandingkan performa antara eksekusi sekuensial dan paralel berdasarkan waktu eksekusi yang dihasilkan.

5. Evaluasi dan Pemeliharaan

Tahap ini dilakukan untuk mengevaluasi kinerja sistem secara keseluruhan, termasuk analisis percepatan (*speedup*) yang dihasilkan dari penerapan paralelisme. Selain itu, dilakukan perbaikan jika ditemukan kekurangan pada sistem.

D. Algoritma K-Means

Algoritma *K-Means* adalah teknik pengelompokan data non-hierarki (sekatan) yang bertujuan untuk membagi data yang sudah ada ke dalam dua atau lebih belas kelompok. Metode ini membagi data ke dalam kelompok sehingga data

dari kelompok yang berbeda dapat memiliki karakteristik yang sama. Tujuan pengelompokan data ini adalah untuk mengurangi fungsi objektif proses pengelompokan, yang biasanya berusaha untuk meminimalkan variasi dalam kelompok dan memaksimalkan variasi antar kelompok [10].

Algoritma *K-Means* mengelompokkan banyak data menjadi kelompok-kelompok data khusus yang merupakan salah satu fitur data mining. Keunggulan metode McQueen adalah kemampuan untuk mengelompokkan dokumen dalam jumlah besar dengan waktu komputasi yang cepat. Metode ini bekerja dengan mengumpulkan dokumen menjadi beberapa kelompok dan secara acak menentukan centroid, atau titik pusat awal. Meskipun demikian, pendekatan *K-Means* ini memiliki kelemahan bahwa ia sensitif terhadap outlier [11]. Berikut merupakan cara kerja dari *Algoritma K-Means Clustering* [12]:

1. Memilih secara acak sejumlah kkk data sebagai pusat *cluster* (centroid).
2. Menghitung jarak antara setiap data dengan pusat *cluster* menggunakan metode *Euclidean Distance*. Perhitungan jarak tersebut dirumuskan sebagai berikut:
$$D(i,j) = \sqrt{(X_{1i} - X_{1j})^2 + (X_{2i} - X_{2j})^2 + \dots + (X_{ki} - X_{kj})^2}$$
3. Menempatkan setiap data ke dalam *cluster* yang memiliki jarak terdekat terhadap pusat *cluster*.
4. Menentukan kembali pusat *cluster* (centroid) yang baru berdasarkan rata-rata data yang telah masuk ke dalam masing-masing *cluster*.
5. Mengulangi proses perhitungan jarak dan pembaruan pusat *cluster* hingga nilai centroid tidak mengalami perubahan (konvergen).


IV. HASIL DAN PEMBAHASAN

Pengujian dilakukan dengan menjalankan algoritma *K-Means* secara serial dan paralel menggunakan MPI (Message Passing Interface) pada satu komputer dengan prosesor AMD Ryzen 7 7700U. Setiap kombinasi pengujian dijalankan sebanyak 3 kali percobaan, kemudian diambil nilai rata-ratanya. Parameter yang digunakan adalah *cluster* K=5 dan toleransi konvergensi 1e-4. Variabel yang diuji meliputi:

1. Jumlah data: 1.000, 5.000, 10.000, 25.000, 50.000, 75.000, dan 100.000
2. Jumlah proses (N): 2, 4, 6, dan 8

A. Perbandingan Metode Serial dan Paralel

1. Grafik hasil pengujian



Gambar 2. Grafik Pengaruh Variasi Ukuran Data

Grafik di atas menunjukkan rata-rata waktu komputasi (dalam detik) untuk berbagai jumlah data terhadap berbagai jumlah proses yang digunakan. Sumbu horizontal merepresentasikan ukuran data yang diuji, sedangkan sumbu vertikal menunjukkan rata-rata waktu komputasi yang diperoleh. Setiap garis atau batang pada grafik menunjukkan jumlah proses yang berbeda, mulai dari mode serial hingga mode paralel.

2. Pembahasan

Berdasarkan grafik pengujian perbandingan metode serial dan paralel, terlihat bahwa waktu komputasi serial meningkat secara konsisten seiring bertambahnya jumlah data, yaitu dari 0,0023 detik pada 1.000 data hingga 0,1605 detik pada 100.000 data. Peningkatan ini menunjukkan bahwa semakin banyak data yang diproses, semakin besar pula beban komputasi yang harus ditangani oleh algoritma K-Means.

Sementara itu, implementasi paralel menggunakan MPI mampu menurunkan waktu komputasi pada data berukuran besar. Pada data 100.000, waktu komputasi serial sebesar 0,1605 detik berhasil diturunkan menjadi 0,0875 detik menggunakan 8 proses. Hal ini menunjukkan penurunan waktu komputasi sekitar 45%. Selain itu, garis paralel dengan jumlah proses yang lebih banyak ($N=6$ dan $N=8$) secara konsisten berada di bawah garis serial pada ukuran data 25.000 hingga 100.000, yang menunjukkan bahwa paralelisasi memberikan manfaat ketika volume data yang diproses cukup besar.


Namun, pada data berukuran kecil (1.000 hingga 10.000), waktu komputasi paralel cenderung lebih tinggi dibandingkan serial.

Sebagai contoh, pada data 1.000, waktu komputasi serial hanya 0,0023 detik, sedangkan paralel dengan 2 proses memerlukan 0,0099 detik. Kondisi ini terjadi karena overhead komunikasi MPI, seperti proses scatter, broadcast, allreduce, dan gather, lebih besar dibandingkan waktu komputasi yang dibutuhkan untuk mengolah data. Akibatnya, keuntungan dari paralelisasi belum dapat menutupi biaya komunikasi antar proses.

Secara keseluruhan, hasil pengujian menunjukkan bahwa efektivitas paralelisasi MPI sangat dipengaruhi oleh ukuran data. Semakin besar jumlah data yang diproses, semakin besar pula keuntungan yang diperoleh dari pembagian beban komputasi ke beberapa proses. Sebaliknya, pada data berukuran kecil, overhead komunikasi masih menjadi faktor dominan sehingga kinerja paralel belum mampu melampaui metode serial secara optimal.

B. Analisis Variasi Jumlah Proses (N)

1. Grafik hasil pengujian



Gambar 3. Grafik Variasi Jumlah Proses (N)

Grafik di atas menunjukkan data waktu komputasi (dalam detik) untuk berbagai jumlah proses terhadap berbagai jumlah data. Sumbu horizontal menunjukkan jumlah proses yang digunakan, sedangkan sumbu vertikal menunjukkan waktu komputasi yang dihasilkan. Setiap garis atau batang pada grafik merepresentasikan ukuran data yang berbeda, sehingga mempermudah pengamatan terhadap pengaruh penambahan jumlah proses terhadap waktu komputasi.

2. Pembahasan

Berdasarkan Grafik Pengujian 2 untuk Waktu Komputasi, terlihat bahwa peningkatan jumlah proses secara umum mampu menurunkan waktu komputasi,

terutama pada data berukuran besar. Pada data 100.000, waktu komputasi menurun secara bertahap dari 0,1775 detik pada N=2 menjadi 0,0994 detik pada N=4, kemudian 0,0885 detik pada N=6, dan 0,0875 detik pada N=8. Hasil ini menunjukkan bahwa pembagian beban kerja ke lebih banyak proses dapat mempercepat proses komputasi algoritma K-Means.

Penurunan waktu komputasi paling signifikan terjadi saat jumlah proses ditingkatkan dari 2 menjadi 4. Pada data 100.000, waktu komputasi berkurang sekitar 44%, menunjukkan bahwa distribusi pekerjaan menjadi lebih efektif. Namun, setelah mencapai 4 proses, laju penurunan waktu mulai melambat. Dari N=6 ke N=8, waktu komputasi hanya berkurang sekitar 1%, yang mengindikasikan adanya batas efisiensi paralelisasi. Pada kondisi ini, tambahan proses tidak lagi memberikan peningkatan kinerja yang signifikan karena overhead komunikasi antar proses mulai meningkat.

Pada data berukuran kecil (1.000 hingga 5.000), grafik menunjukkan pola yang cenderung fluktuatif dan tidak konsisten. Sebagai contoh, pada data 5.000, waktu komputasi sebesar 0,0136 detik pada N=2 turun menjadi 0,0077 detik pada N=4, kemudian meningkat menjadi 0,0127 detik pada N=6, dan kembali turun menjadi 0,0092 detik pada N=8. Fluktuasi ini terjadi karena waktu komputasi yang relatif sangat singkat membuat overhead komunikasi MPI menjadi faktor yang lebih dominan dibandingkan proses perhitungan itu sendiri.

Secara keseluruhan, hasil pengujian menunjukkan bahwa penambahan jumlah proses dapat meningkatkan performa komputasi algoritma K-Means, terutama pada dataset berukuran besar. Akan tetapi, peningkatan tersebut tidak bersifat linear karena adanya overhead komunikasi yang semakin besar seiring bertambahnya jumlah proses. Oleh karena itu, jumlah proses yang digunakan perlu disesuaikan dengan ukuran data agar diperoleh keseimbangan antara percepatan komputasi dan biaya komunikasi.

C. Rata-Rata Kinerja Waktu Komputasi K-Means pada Analisis Data Transaksi

Setelah menjalankan tiga kali percobaan untuk setiap kombinasi pengujian, berikut adalah hasil rata-rata dari ketiga percobaan tersebut. Nilai rata-rata ini memberikan gambaran yang lebih stabil dan representatif tentang kinerja paralelisasi K-Means menggunakan MPI.

Tabel D.2 Rata-rata Waktu Komputasi (detik) - Percobaan 1, 2, 3

	1.000	5.000	10.000	25.000	50.000	75.000	100.000
1 (Serial)	0,0023	0,0048	0,0092	0,0132	0,0106	0,1320	0,1405
2	0,0009	0,0136	0,0137	0,0478	0,0620	0,3834	0,1375
4	0,0008	0,0077	0,0077	0,0170	0,0417	0,0700	0,0994
6	0,0071	0,0127	0,0113	0,0225	0,0297	0,0623	0,0885
8	0,0090	0,0092	0,0083	0,0156	0,0258	0,0610	0,0875

Gambar 4. Rata-rata Pengujian 1 Waktu Komputasi

Tabel di atas menunjukkan rata-rata waktu komputasi (detik) dari tiga percobaan untuk berbagai jumlah data terhadap berbagai jumlah proses. Waktu komputasi hanya mengukur durasi proses inti algoritma K-Means yaitu tahap assignment dan update centroid.

Tabel D.4 Rata-rata Waktu Komputasi (detik) - Percobaan 1, 2, 3

	1 (Serial)	2	4	6	8
1.000	0,0023	0,0009	0,0008	0,0071	0,0090
5.000	0,0048	0,0136	0,0077	0,0127	0,0092
10.000	0,0092	0,0177	0,0077	0,0113	0,0083
25.000	0,0332	0,0478	0,0170	0,0225	0,0156
50.000	0,0506	0,0620	0,0417	0,0297	0,0258
75.000	0,1320	0,3834	0,0700	0,0623	0,0610
100.000	0,1405	0,1375	0,0994	0,0885	0,0875

Gambar 5. Rata-rata Pengujian 2 Waktu Komputasi

Tabel di atas menunjukkan rata-rata waktu komputasi (detik) dari tiga percobaan untuk berbagai jumlah N terhadap berbagai jumlah data.

V. KESIMPULAN DAN SARAN

Dalam penelitian ini, algoritma *K-Means* digunakan dengan sukses untuk melakukan segmentasi pelanggan secara otomatis dan terstruktur berdasarkan data transaksi penjualan. Hasil pengelompokan menunjukkan bahwa berdasarkan kemiripan karakteristik transaksi, data pelanggan dapat dibagi ke dalam beberapa kelompok. Selain itu, telah terbukti bahwa penggunaan komputasi paralel dapat meningkatkan kinerja sistem. Sistem yang dikembangkan tidak hanya dapat menggantikan proses manual menjadi lebih efisien, tetapi juga dapat memberikan hasil analisis yang lebih cepat dan akurat untuk membantu memahami pola perilaku pelanggan dengan lebih baik, seperti yang ditunjukkan oleh waktu eksekusi yang lebih cepat untuk penggunaan beberapa pekerja daripada satu pekerja.

VI. UCAPAN TERIMA KASIH

Penulis mengucapkan terima kasih kepada seluruh pihak yang telah memberikan dukungan, bantuan, dan kontribusi selama proses penelitian serta penyusunan paper ini. Ucapan terima kasih secara khusus disampaikan kepada dosen pembimbing yang telah memberikan arahan, masukan, dan bimbingan sehingga penelitian ini dapat diselesaikan dengan baik. Penulis juga mengucapkan terima kasih kepada Universitas Mataram atas dukungan akademik dan fasilitas yang diberikan selama pelaksanaan penelitian. Selain itu, apresiasi disampaikan kepada keluarga, teman, dan rekan-rekan yang telah memberikan motivasi serta dukungan selama proses penyusunan penelitian ini. Semoga penelitian ini dapat memberikan manfaat bagi pengembangan ilmu pengetahuan, khususnya di bidang komputasi paralel dan data mining.

DAFTAR PUSTAKA

- [1] T. Hidayat et al., “Penerapan Data Mining untuk Segmentasi Pelanggan Menggunakan Metode K-Means,” *Jurnal Teknologi Informasi dan Ilmu Komputer (JTIK)*, 2020.
- [2] E. Prasetyo and A. Wibowo, “Analisis Clustering Menggunakan Metode K-Means pada Data Pelanggan,” *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*, 2019.
- [3] D. P. Sari et al., “Implementasi Algoritma K-Means untuk Segmentasi Pelanggan pada Data Penjualan,” *Jurnal Informatika*, 2021.
- [4] T. Hidayat et al., “Penerapan Data Mining untuk Segmentasi Pelanggan Menggunakan Metode K-Means,” *Jurnal Teknologi Informasi dan Ilmu Komputer (JTIK)*, 2020.
- [5] E. Prasetyo and A. Wibowo, “Analisis Clustering Menggunakan Metode K-Means pada Data Pelanggan,” *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*, 2019.
- [6] D. P. Sari et al., “Implementasi Algoritma K-Means untuk Segmentasi Pelanggan pada Data Penjualan,” *Jurnal Informatika*, 2021.
- [7] S. N. Syari, F. Pradana, and I. Bastari, “Penerapan Data Mining untuk Clustering Menu Favorit Menggunakan Algoritma K-Means,” *JINACS (Journal of Informatics and Computer Science)*, vol. 3, no. 4, pp. 438–445, 2022.
- [8] A. S. M. Lumenta, A. A. Sinsuw, and X. B. Najoran, “Studi Performa PC Cluster,” *Jurnal Teknik Elektro dan Komputer*, vol. 3, no. 2, pp. 1–7, 2014.
- [9] A. Yahya and R. Kurniawan, “Implementation of K-Means Algorithm for Clustering Sales Data Based on Sales Patterns,” 2025.
- [10] A. Yahya and R. Kurniawan, “Implementation of K-Means Algorithm for Clustering Sales Data Based on Sales Patterns Implementasi Algoritma K-Means untuk Pengelompokan Data Penjualan Berdasarkan Pola Penjualan,” vol. 5, no. 1, pp. 350–358, Jan. 2025.
- [11] A. R. Danurisa and J. Heikal, “Customer Clustering Using the K-Means Clustering Algorithm in the Top 5 Online Marketplaces in Indonesia,” *Budapest International Research and Critics Institute (BIRCI-Journal)*, vol. 5, no. 3, 2022.
- [12] A. N. Khormarudin, “Teknik Data Mining: Algoritma K-Means Clustering,” *Jurnal Ilmu Komputer*, pp. 1–12, 2016.

